

Universidad de Buenos Aires
Laboratorio de Sistemas Embebidos
Especialización en Inteligencia Artificial

Trabajo Práctico Final

Análisis predictivo del precio de Bitcoin usando modelos de Deep Learning

Docente: Dr. Camilo Argoty

Noelia Melina Qualindi
Jorge Valdez
Fabián Sarmiento
Matías Marando

19 de junio de 2025

Resumen

Este trabajo presenta un análisis comparativo de modelos avanzados de deep learning para la predicción del precio de Bitcoin (BTC-USD). Se implementaron y evaluaron cuatro arquitecturas: Transformer Vanilla para series temporales, TFT (*Temporal Fusion Transformer*), Informer y NHiTS (*Neural Hierarchical Interpolation for Time Series*), utilizando datos históricos desde 2012 hasta la fecha. Los resultados demuestran que los modelos pueden capturar patrones complejos en los datos. El estudio incluye un análisis exhaustivo de preprocesamiento, diseño de modelos y validación de resultados, concluyendo con recomendaciones para futuras mejoras.

1. Introducción

Las criptomonedas han emergido como una clase de activos revolucionaria que ha transformado el panorama financiero global desde la introducción de Bitcoin en 2009. Particularmente Bitcoin, como la primera y más establecida criptomoneda, presenta desafíos únicos y complejos para el análisis predictivo que la distinguen significativamente de los activos financieros tradicionales.

La naturaleza descentralizada de Bitcoin, combinada con su extrema volatilidad de precios, crea un entorno de trading caracterizado por fluctuaciones dramáticas que pueden superar el 10-20 % en períodos de 24 horas. Esta volatilidad intrínseca se ve amplificada por múltiples factores: la alta sensibilidad a noticias regulatorias, eventos geopolíticos, decisiones de grandes instituciones, movimientos de "ballenas" (grandes tenedores), cambios en la percepción pública, y la influencia de redes sociales y figuras públicas influyentes. A diferencia de los mercados financieros tradicionales, Bitcoin opera en un mercado global 24/7 sin interrupciones, lo que genera patrones temporales únicos y ausencia de los típicos efectos de cierre de mercado. Además, la relativa juventud del mercado cripto significa que los modelos deben adaptarse a un ecosistema en constante evolución con datos históricos limitados comparados con mercados centenarios. Dada la creciente adopción institucional de Bitcoin y su integración en portafolios de inversión *mainstream*, existe una necesidad crítica de desarrollar modelos predictivos robustos que puedan manejar estas características únicas. Este trabajo busca responder el siguiente planteamiento:

¿Pueden los modelos modernos de deep learning predecir efectivamente el precio de Bitcoin a corto plazo, y cómo se comparan diferentes arquitecturas en este contexto?

2. Metodología

2.1. Datos Utilizados

El dataset empleado presenta las siguientes características:

- **Fuente:** Kaggle (Bitcoin Historical Data)
- **Período:** 2012-01-01 a 2025-06-??
- **Variables utilizadas:**

Variable	Descripción
Timestamp	Fecha en formato UNIX
Close	Precio de cierre (USD)

2.2. Preprocesamiento

El preprocesamiento de los datos se realizó en varias etapas clave:

1. **Limpieza de datos:** Se comenzó renombrando las columnas relevantes para facilitar su uso posterior, en particular la marca temporal y el precio de cierre. Luego, se eliminaron todas las filas que contenían valores nulos en la columna del precio, asegurando que todos los datos utilizados para el análisis fuesen válidos.
2. **Conversión de tiempo:** La columna de tiempo original, que venía en formato UNIX (segundos desde 1970), fue convertida a un formato de fecha estándar para su correcta interpretación y manipulación.
3. **Ordenamiento temporal:** Se ordenaron los datos cronológicamente según la fecha, para asegurar la coherencia temporal en los análisis y predicciones.
4. **Resampleo diario:** Dado que los datos originales tenían una granularidad de un minuto, se procedió a realizar un promedio diario del precio, lo cual reduce la variabilidad y permite un análisis más robusto en horizontes temporales más amplios.
5. **Normalización:** Se aplicó una normalización de tipo Min-Max al precio diario, escalando los valores al rango $[0, 1]$. Esto facilitó el entrenamiento de los modelos de *deep learning*, ya que evita problemas numéricos asociados a diferentes escalas.
6. **Creación de secuencias:** Para poder alimentar los modelos, los datos fueron transformados en ventanas deslizantes. Se definieron tres longitudes de entrada de: 90, 180 y 365 días y un horizonte de predicción de 10 días. Cada muestra consiste en una secuencia de precios normalizados para entrenar el modelo a predecir el comportamiento futuro.

2.3. Modelos Implementados

Se implementaron cuatro modelos de predicción de series temporales utilizando distintas arquitecturas. Todos los modelos fueron entrenados siguiendo un protocolo estandarizado utilizando tres configuraciones de ventanas de entrada temporales: 30, 60 y 90 días históricos, permitiendo evaluar el impacto de diferentes horizontes de contexto temporal en la capacidad predictiva.

2.3.1. Transformer Vanilla para Series Temporales

El modelo implementado se basa en la arquitectura clásica de encoder-decoder, utilizando mecanismos de atención multi-cabeza.

- Modelo implementado con `darts.models.TransformerModel`.
- Hiperparámetros clave:
 - Dimensión del modelo (`d_model`): 64
 - Número de capas: 2 encoder y 2 decoder
 - Cabezas de atención: 4
 - Dropout: 0.1
 - Épocas: 100

2.3.2. Modelo NHiTS

NHiTS (Neural Hierarchical Interpolation for Time Series) es una arquitectura de pronóstico que combina bloques jerárquicos de interpolación con descomposición de señales.

- Modelo implementado con `darts.models.NHiTSModel`.
- Hiperparámetros clave:
 - Bloques jerárquicos: 1
 - Capas por bloque: 2
 - Ancho de cada capa: 64
 - Dropout: 0.1
 - Épocas: 100

2.3.3. Modelo TFT

El modelo TFT es una arquitectura avanzada de deep learning diseñada específicamente para el pronóstico de series temporales multivariadas. Desarrollado por Google Research, combina la potencia de los mecanismos de atención de los Transformers con técnicas especializadas para el manejo de datos temporales.

Los parámetros considerados para el entranamiento de este modelo se describen a continuación.

- Modelo implementado con `darts.models.TFTModel`.

- Hiperparámetros clave:
 - Bloques jerárquicos: 1
 - Capas por bloque: 2
 - Ancho de cada capa: 64
 - Dropout: 0.1
 - lstm layers: 2
 - Épocas: 100

2.3.4. Modelo Informer

Informer es una arquitectura de aprendizaje profundo diseñada específicamente para la predicción eficiente y escalable de series temporales, en particular para tareas de predicción de secuencias largas. Se presentó en el artículo "*Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting*" by Zhou et al., 2021".

- Modelo implementado con `darts.models.NHiTSModel`.
- Hiperparámetros clave:
 - Capas ocultas convolucionales: 64
 - Número de cabezas: 2
 - Número de capas ocultas: 32
 - Ancho de cada capa: 64
 - Dropout: 0.3
 - Épocas: 500

3. Resultados

3.1. Validación del Modelo

Se utilizó una división del dataset en:

- 80 % para entrenamiento
- 10 % para validación
- 10 % para prueba

Se aplicó **early stopping** para evitar overfitting, con una tolerancia de 5 épocas. También se probaron distintos horizontes de predicción (5, 10, 15 días), confirmando que el rendimiento decae a medida que aumenta el horizonte.

3.2. Métricas de evaluación

En las tablas 1 a 3 se muestran las métricas obtenidas para cada una de las ventanas de tiempo de entrenamiento consideradas.

Tabla 1: Métricas de desempeño por ventana de entrenamiento (1 año).

Métrica	Transformer	NHiTs	TFT	Informer
MAE (USD)	0.006970	0.01910	0.06530	0.02220
RMSE (USD)	0.07370	0.02250	0.09380	0.02810
MAPE (%)	11.47	3.19	10.80	3.72

Tabla 2: Métricas de desempeño por ventana de entrenamiento (6 meses).

Métrica	Transformer	NHiTs	TFT	Informer
MAE (USD)	0.002760	0.02170	0.04090	0.01400
RMSE (USD)	0.03150	0.02550	0.05440	0.01680
MAPE (%)	4.58	3.62	6.70	2.33

Tabla 3: Métricas de desempeño por ventana de entrenamiento (1 año).

Métrica	Transformer	NHiTs	TFT	Informer
MAE (USD)	0.002340	0.02830	0.03020	0.01940
RMSE (USD)	0.02640	0.03280	0.03640	0.02330
MAPE (%)	3.90	4.72	4.90	3.17

En las figuras 1 a 3 se observan las diferentes métricas (MAE, MAPE, RMSE) obtenidas y las ventanas de tiempo consideradas.




Figura 1: Comparativa MAE vs ventana de entrenamiento.




Figura 2: Comparativa MAPE vs ventana de entrenamiento.




Figura 3: Comparativa RMSE vs ventana de entrenamiento.

3.3. Predicciones de los diferentes modelos

En las figuras 4 a 6 se podrán observar las predicciones de los modelos evaluados en este trabajo.




Figura 4: Predicciones vs Real a 10 días - ventana de entrenamiento 3 meses




Figura 5: Predicciones vs Real a 10 días - ventana de entrenamiento 6 meses




Figura 6: Predicciones vs Real a 10 días - ventana de entrenamiento 1 año

4. Conclusiones

4.1. Hallazgos Clave

- Los modelos Informer y NHiTs demostraron un rendimiento superior consistente en comparación con los demás modelos evaluados (TFT y Transformer), obteniendo los mejores resultados en todas las métricas de evaluación consideradas en este estudio: MAE, MAPE y RMSE. Esta superioridad puede atribuirse a las innovaciones arquitectónicas específicas de cada modelo. El Informer destaca por su mecanismo ProbSparse self-attention que reduce significativamente la complejidad computacional mientras mantiene la capacidad de capturar dependencias de largo plazo en series temporales extensas. Por su parte, NHiTs aprovecha su arquitectura jerárquica de interpolación que permite una descomposición eficiente de las series temporales en múltiples escalas temporales, capturando tanto patrones locales como tendencias globales. Los resultados sugieren que estas arquitecturas más recientes han logrado abordar efectivamente las limitaciones de los modelos Transformer tradicionales y TFT en el contexto específico del pronóstico de series temporales, ofreciendo no solo mayor precisión sino también mejor eficiencia computacional.
- Los modelos evaluados presentaron limitaciones significativas durante eventos de alta volatilidad, evidenciando una disminución notable en la precisión de las predicciones cuando las series temporales experimentaron cambios abruptos o patrones irregulares.
- La arquitectura de atención demostró ser particularmente efectiva para capturar dependencias a largo plazo

4.2. Limitaciones y Trabajo Futuro

- **Limitaciones:**
 - Sensibilidad a cambios bruscos de tendencia
 - Dependencia de hiperparámetros
- **Mejoras propuestas:**
 - Incorporar datos de redes sociales (sentiment analysis)
 - Ensamblar múltiples modelos
 - Incluir datos de inflación, políticas monetarias, y correlaciones con mercados tradicionales

Anexo

El código completo se encuentra disponible en:
<https://github.com/BenjaSar/AdST2>